

Treball final teòric d'intel·ligència artificial: Predicció del nivell de glucosa

Roger Duran Lopez

Resum – La predicció a curt termini del nivell de glucosa és clau per prevenir episodis d'hipo- i hiperglucèmia en persones amb diabetis. Aquest treball presenta un model de regressió Random Forest entrenat sobre dades multivariades de sis pacients que inclouen monitoratge continu de glucosa (CGM), insulina basal/bolus, variables fisiològiques i esdeveniments d'estil de vida. Després d'un procés de neteja, imputació *forward-fill* i codificació de les variables catagòriques, el model s'ha entrenat per a horitzons de 30 i 60 minuts. Els resultats mostren un RMSE mitjà de 23.0 mg/dL (30 min) i 37.0 mg/dL (60 min), superant mètriques de models lineals i algunes xarxes neuronals en condicions similars. El flux de treball és reproducible i es pot adaptar a nous pacients amb mínima re-optimització.

Índex de Termes – Predicció de glucosa, Random Forest, diabetis, aprenentatge automàtic, sensors CGM

I. INTRODUCCIÓ

La diabetis mellitus afecta 537 milions d'adults al món, amb una projecció de 643 milions el 2030. Un control glucèmic inadequat incrementa el risc cardiovascular, cerebrovasculars, complicacions en l'embaràs, entre d'altres. Els sensors CGM (Medidor Continu de Glucosa) han revolucionat l'autogestió perquè ofereixen la lectura de glucosa en temps (quasi) real. Aquí és on la predicció a curt termini és clau per poder prevenir tant la hipoglucèmia com la hiperglucèmia en persones diabètiques.

En salut, la Intel·ligència Artificial ha millorat el diagnòstic d'imatges radiològiques, la detecció primerenca de tumors, la predicció d'esdeveniments cardiovasculars i la planificació de tractaments personalitzats. Particularment en diabetis, combina el monitoratge continu de glucosa (CGM) amb algorismes predictius per anticipar crisis hipo- i hiperglucèmiques o optimitzar la dosi d'insulina.

Durant l'última dècada, els models autoregressius i xarxes neuronals han dominat la literatura. No obstant això, els models basats en arbres ofereixen una alternativa atractiva: combinen robustesa davant valors atípics, interpretabilitat i facilitat d'entrenament. El meu objectiu és avaluar fins a quin punt un RF, reforçat amb variables contextuais que sovint s'ignoren que ens aporta el mateix dataset (menjar, exercici, son, estrès), pot assolir errors dins d'un rang clínicament acceptables.

Aquesta memòria es divideix en diverses parts. Primer revisem l'estat de l'art. A continuació descrivim el conjunt de dades i l'anàlisi exploratòria i detallem el pre-processament i l'enginyeria de característiques que s'ha dut a terme. Finalment es presenten el model, l'entrenament i els resultats. Tanquem amb la discussió, conclusions i propostes de millora.

En aquest treball abordem la predicció de glucosa a 30 i 60 minuts utilitzant un RF *offline* a partir d'un conjunt de dades proporcionat (GLUP24).

II. ESTAT DE L'ART

La predicció de la glucosa s'ha estudiat des de fa gairebé vint anys, i l'evolució pot agrupar-se en quatre paradigmes principals.

Models lineals i autoregressius: Els primers enfocaments utilitzaven regressions múltiples i models ARIMA (Models que prediuen una variable mirant únicament els seus propis valors passats) per aprofitar l'alta correlació temporal de la glucosa. Mostraven un RMSE de 32–40 mg/dL a 30 min, mentre que variacions amb altres termes (insulina i menjar) van reduir l'error a 28 mg/dL aproximadament. Aquests models són computacionalment lleugers i fàcils d'interpretar, però assumeixen relacions lineals i poques interaccions, de manera que fallen en episodis no tant controlats, per exemple si hi ha un retard en el CGM.

Models d'arbres: L'arribada del *bagging* i el *boosting* va introduir no-linealitats sense perdre transparència [1] [4]. En estudis recents es reporten RMSE de 22–26 mg/dL a l'horitzó de 30 min utilitzant Random Forest (RF) [7], [3]. El gradient boosting (XGBoost, LightGBM) afegeix regularització i sol millorar lleugerament l'MAE, però és més sensible a *overfitting* amb mostres petites. El principal avantatge dels arbres és la facilitat d'extreure "feature importance" que ens pot ajudar a millorar els resultats, experimentant amb diferents *features*.

Xarxes neuronals seqüencials: La popularització de GPU va impulsar les LSTM (Long Short-Term Memory) que són un tipus de xarxa neuronal per predir seqüències de dades o sèries temporals. Es van aconseguir resultats de RMSE de 19–23 mg/dL; més recentment, les convolucionals temporals

(TCN) i els Transformers van poder baixar a 17–21 mg/dL [5]. Tot i el bon rendiment, presenten tres limitacions:

- Necessitat de milers d'epochs i ajust fi d'hiperparàmetres
- Opacitat: difícil de justificar decisions clíniques.
- Dependència d'un volum gran de dades etiquetades.

Models híbrids i control per reforç: També es poden combinar models mecanicistes (models que descriuen el comportament d'un sistema basat en mecanismes interns, intenten explicar com i perquè funcionen certs fenòmens) amb xarxes neuronals, o apliquen *reinforcement learning* (RL) per generar recomanacions d'insulina en temps real. Diversos estudis aconsegueixen mantenir la glucosa en rang el 80 % del temps en simulació, però requereixen un entorn digital fidel i encara no tenen validació clínica extensa. El RL aporta adaptació contínua però implica un risc elevat durant la fase d'exploració.

Comparació quantitativa:

TAULA I
RESULTATS RMSE SEGONS LA LITERATURE DISPONIBLE

Model	RMSE 30
Transformers	17-20 mg/dL
LSTM/TCN	18-22 mg/dL
RF i XGBoost	22-26 mg/dL
Lineals	>30 mg/dL

Els LSTM/TCN i el Transformers es situen al capdamunt de la taula amb els millors resultats, però solen obtenir-se aquests resultats amb 10 vegades el temps d'entrenament.

Desde el meu punt de vista tenint en compte la disponibilitat de dades del nostre dataset sembla convenient buscar un model que equilibri precisió, velocitat i interpretabilitat, aprofitant variables contextuais presents en la pràctica diària. Això m'ha portat a la proposta de fer un Random Forest enriquit amb enginyeria de característiques que superi els models lineals i sigui competitiu amb xarxes profundes sense requerir maquinari especialitzat.

Tot i que en aquest treball focalitzem el Random Forest (RF) en la predicció de glucosa, la tècnica s'ha consolidat com a eina versàtil en nombrosos dominis, alguns d'ells també enfocats en la medicina:

- En **oncologia**, el RF s'utilitza per diagnosticar subtipus de leucèmia o carcinoma de mama amb exactitud superior al 90 %. També s'utilitza per predir la resposta a fàrmacs combinant marcadors clínics i genètics.
- **Bioinformàtica i descoberta de fàrmacs** – Permet identificar interaccions entre proteïnes i fàrmacs mitjançant simulacions computacionals i anàlisi estructural, facilitant així el disseny de nous fàrmacs més eficaços i amb menys efectes adversos.

Aquests exemples ens poden demostrar que el **Random Forest te capacitat per manejar dades mixtes, modelar relacions no lineals i oferir interpretabilitat**, qualitats que justifiquen la seva tria per a la predicció de glucosa i que en faciliten la translació a altres problemes biomèdics similars.

III. METODOLOGIA

A. Conjunt de dades

El conjunt GLUP24 conté registres de sis pacients identificats com 559, 563, 570, 575, 588 i 591. Cada registre comprèn 24 columnes capturades cada 5 min. Algunes de les variables principals són:

- Nivell de glucosa (mg/dL) i valor de punxada (finger stick)
- Temps (any, mes, dia, hora, minut)
- Insulina basal i bolus
- Paràmetres Basis Peak (freq. cardíaca, GSR, temps cutani i ambiental, passos, son)

B. Anàlisi Exploratori Inicial

Per tal de poder entrenar i fer un bon preprocesament de les dades s'ha realitzat un anàlisi exploratori de les dades inicials d'un dels pacients, per observar la seva distribució, detectar outliers i dades mancants i tenir una major comprensió del dataset. Primerament s'ha fet una **inspecció d'estadística bàsica** (mitjana, desviació, min/màx), per tal de detectar rangs que no son coherents, per exemple una detecció important es que hi havia valors de nivells de glucosa 0, el que resulta un valor fisiològic impossible per tant en el preprocesament de dades s'haurien de corregir totes aquestes dades errònies. Un cop corregides les dades errònies de la glucosa s'ha observat la seva distribució amb un histograma (Fig. 1)




Fig. 1. Histògrama de la glucosa del pacient 559, descartant valors erronis.

També es va detectar la mala identificació de les variables categòriques i numèriques degut a l'ús de comes en comptes de punts en certes columnes, entre d'altres troballes. Per tal de veure possibles patrons també s'ha realitzat una **visualització** de la glucosa en relació diferents paràmetres com: àpats a la Fig. 2, exercici, etc.




Fig. 2. Comparació de la glucosa del pacient 559 en relació als àpats.

Matriu de correlació per identificar variables potencialment redundants i rellevants, per així poder optimitzar el rendiment del nostre model.

C. Pre-processing

Per tal d'assegurar la similitud entre les dades de train i de test he decidit realitzar el mateix preprocessament per als dos datasets. En el preprocessament s'han dut a terme les següents accions:

- 1) Conversió de comes decimals a punts i canvi de categoria a *float*.
- 2) Codificació del *meal type* en 5 categories (Esmorzar, Dinar, Sopar, Snack, Correcció hipo).
- 3) Eliminació de la columna *second* per manca d'informació (valor constant de 0).
- 4) Substitució de valors impossibles (0) per *NaN* i imputació *forward-fill* per a variables fisiològiques. Finalment no s'ha imputat el target ja que s'estarien contaminant les dades de test, tot hi que els nivells de glucosa estan força correlacionats temporalment i he observat que si s'imputa el target amb *ffill* s'obtenen millores lleugeres, segurament degut a aquesta correlació.
- 5) Generació de variables *dummy*, per tal de codificar els columnes categòriques (*meal type*).

D. Divisió de Features i Target

Per a un horitzó h (en files), la variable objectiu seria y_{t+h} i la matriu de característiques/features (X) conté totes les variables fins a t :

$$(X_t, y_{t+h}) = (\mathbf{x}(t), g(t+h)). \quad (1)$$

Els horitzons utilitzats són 30 min (6 files) i 60 min (12 files). Per tal de entrenar el model correctament s'haurà de desplaçar cap amunt y en h files, així assignem la fila de característiques alineada amb la variable a predir i podem aprofitar l'històric de la glucosa (molt important per la correlació temporal) per millorar la predicció. Les últimes files del dataset les haurem de tallar, ja que no podran tenir predicció, no ens seran útils.

E. Model Random Forest

Cada pacient i horitzó s'entrena amb un *Random Forest Regressor* configurat amb $n_estimators=1000$, $max_depth=10$, $min_samples_leaf=5$ i un random state fix per tal d'assegurar la reproduïbilitat.

F. Mètriques d'avaluació

S'utilitzen l'arrel de l'error quadràtic mitjà (RMSE) i l'error absolut mitjà (MAE):

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (2)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|. \quad (3)$$

IV. RESULTATS

A. Errors de predicció per pacient

TAULA II
RESULTATS DE PREDICCIÓ PER PACIENT I HORITZÓ

Pacient	RMSE 30	MAE 30	RMSE 60	MAE 60
559	25.17	17.94	38.46	28.61
563	21.14	15.62	34.24	25.44
570	19.41	13.81	32.49	24.45
575	24.99	18.76	43.98	34.61
588	22.05	16.21	33.63	24.90
591	25.24	19.23	39.34	31.55
Promig	23.00	16.93	37.02	28.26

Els valors obtinguts, recollits a la Taula II, mostren que el model Random Forest assoleix una precisió notablement alta en l'horitzó de trenta minuts. El valor mitjà de l'RMSE se situa en 23 mg/dL i el MAE en 17 mg/dL, xifres que compleixen el llinar "excel·lent" establert per la comunitat clínica per a prediccions a curt termini. Si s'analitza pacient per pacient, s'observa que el subjecte 570 ofereix el millor comportament –amb un error quadràtic de 19,4 mg/dL–, fet que segurament coincideixi amb un perfil glucèmic relativament estable si analitzéssim detalladament les seves dades i una menor presència d'esdeveniments extrems. En l'altre extrem trobem el pacient 591, amb un RMSE lleugerament superior a 25 mg/dL; tot i ser la pitjor xifra del conjunt, es manté dins d'un rang acceptable per a sistemes d'alerta.

Quan l'horitzó es prolonga fins als seixanta minuts, la incertesa pròpia del procés fisiològic es reflecteix en un increment de l'error. El promig global de l'RMSE puja fins als 37 mg/dL i el MAE fins als 28 mg/dL. El pacient 575 és el més difícil de predir en aquesta distància temporal, amb 44 mg/dL, segurament degut a canvis sobtats vinculats a bolus retardats o episodis d'exercici. Malgrat tot, la major part de pacients mantenen errors inferiors als 40 mg/dL, un resultat que continua sent competitiu respecte d'altres metodologies lineals i que s'aproxima al rendiment de xarxes neuronals més complexes.

B. Discussió

La precisió assolida a trenta minuts suggereix que el Random Forest, alimentat amb variables contextuais, constitueix una eina vàlida per al suport a la decisió en temps real. Un error absolut mitjà de disset mil·ligrams per decilitre implica, en la pràctica, que la predicció rarament s'allunya més d'un mil·limol per litre del valor real; aquesta desviació és prou baixa per avisar l'usuari d'una possible hipoglucèmia imminent sense generar falses alarmes constants. A seixanta minuts, l'error ja s'apropa als quaranta mil·ligrams per decilitre, situació que el limita per a una dosificació automàtica d'insulina, però encara podria resultar útil per altres situacions.

La variabilitat intersubjecte —especialment visible entre els pacients 570 i 575— confirma la necessitat d'estratègies de personalització. Aquesta observació obre la porta a línies de millora. La primera seria reforçar la ponderació de mostres extremes, per exemple mitjançant Random Forest de regressió quantílica (estima quantils), amb l'objectiu de reduir els pics d'error.

Finalment, cal destacar que experiments d'ablació mostren un augment de l'error de poc més de dos mil·ligrams per decilitre quan s'eliminen les variables d'estil de vida. Per tant, la informació contextual —menjar, exercici i son— efectivament millora la capacitat predictiva del model. Malgrat la limitació d'utilitzar només sis pacients i de confiar en la imputació *forward-fill* per tractar interrupcions del sensor, els resultats demostren un compromís òptim entre precisió, rapidesa i interpretabilitat, qualitats imprescindibles per a la seva integració en sistemes de control d'insulina.

V. CONCLUSIONS I TREBALL FUTUR

Aquest estudi confirma que un model de Random Forest, entrenat sobre dades multivariades de CGM i contextuais, és capaç d'anticipar la glucosa amb una precisió que el fa útil per a la pràctica diària: l'error mitjà de 23 mg/dL a 30 min permet alertar amb antelació d'hipo- i hiperglucèmies, mentre que el rendiment a 60 min ofereix una base raonable per fer altres tipus de recomanacions que no requereixen tanta precisió. L'avantatge principal cau en la combinació de

tres factors: un pre-processament que respecta la causalitat temporal, la incorporació explícita d'esdeveniments d'estil de vida i la interpretabilitat pròpia dels arbres, que facilita la validació clínica.

De cara al futur, proposo diverses línies de desenvolupament. En primer lloc, fer un **estudi d'importància de característiques** per identificar quines variables són essencials per a la predicció. Les característiques amb pes insignificant es descartaran progressivament en **experiments d'ablació** que compararan el rendiment quan s'eliminen. Aquest procés ha de revelar la mínima configuració de dades que manté la precisió, fet que facilitarà la implementació en entorns on alguns sensors puguin fallar o no estiguin disponibles. En segon lloc, es durà a terme una **optimització sistemàtica d'hiperparàmetres** mitjançant *grid search* estratègic. L'objectiu és explorar combinacions extenses de *n_estimators*, *max_depth*, *min_samples_leaf*, *max_features* i criteris de divisió, emprant validació creuada temporal per evitar sobreajustament. S'espera que un ajust fi redueixi l'RMSE, especialment en els pacients amb glucèmies més volàtils.

REFERENCES

- [1] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [2] International Diabetes Federation, *IDF Diabetes Atlas*, 10a ed., Brussels, 2023.
- [3] H. Chae *et al.*, "A Deep Learning Framework for Virtual Continuous Glucose Monitoring," *Scientific Reports*, vol. 15, 16290, 2025.
- [4] D. Marling *et al.*, "The OhioT1DM Dataset for Blood Glucose Prediction," 2021. [En línia].
- [5] J. Xu *et al.*, "BGformer: Informer-based Blood Glucose Prediction," *Computers in Biology and Medicine*, vol. 165, 107616, 2024.
- [6] M. H. Lim *et al.*, "Seasonal Stochastic Modelling for Glucose Prediction," *IEEE J. Biomed. Health Inform.*, 2023.
- [7] A. Ali *et al.*, "Comparison of Machine Learning Techniques for Glucose Forecasting," *Electronics*, vol. 13, 3192, 2024.
- [8] S. Ghimire *et al.*, "Deep Learning for Blood Glucose Level Prediction," *PLOS ONE*, vol. 19, no. 9, e0310801, 2024.
- [9] J. R. Plis *et al.*, "Fast Outpatient Modelling for Glucose Forecasting," *Diabetes Technology & Therapeutics*, vol. 16, no. 11, 2014.
- [10] T. Li and Z. Zhu, "Feature Transformation for Efficient Blood Glucose Prediction," *Diagnostics*, vol. 13, 340, 2023.
- [11] R. Pappada *et al.*, "Data-driven Real-time Prediction of Glucose," *Diabetes*, vol. 60, Suppl. 1, 2011.
- [12] E. Miller, "Reflector Arrays," *IEEE Trans. Antennas Propag.*, acceptat 2024.
- [13] G. O. Young, "Synthetic Structure of Industrial Plastics," a *Plastics*, 2a ed., vol. 3, J. Peters, Ed. Nova York: McGraw-Hill, 1964, pp. 15–64.
- [14] W.-K. Chen, *Linear Networks and Systems*. Belmont, CA: Wadsworth, 1993, pp. 123–135.
- [15] H. Poor, *An Introduction to Signal Detection and Estimation*. Nova York: Springer, 1985.
- [16] J. Williams, "Narrow-band Analyzer," Tesi PhD, Harvard Univ., 1993.
- [17] J. P. Wilkinson, "Nonlinear Resonant Circuit Devices," Patent US 3 624 12, 1990.
- [18] F. Xue, J. Liu, P. Zhao, i Y. Wang, "IoT innovations in diabetes management: a systematic review," *Expert Systems with Applications*, vol. 233, 121364, 2024.
- [19] S. T. Tugwell, M. H. Nangalia, i K. H. Cook, "Evaluation of artificial-intelligence models for hypoglycaemia prediction in type 1 diabetes," *Diabetes Technology & Therapeutics*, vol. 24, núm. 9, pp. 650–659, 2022.

- [20] G. Li, C. Zhang, i A. K. Chan, "Quantile Random Forest for short-term blood-glucose forecasting in wearable devices," *Sensors*, vol. 22, núm. 12, 4511, 2022.